Notícias financeiras e técnicas de PLN

Trabalho da Unidade 3

Marcos Borgert e Vitor Gustavo Hornburg
FURB - Processamento de Linguagem Natural - 2026/2

Contexto e base utilizada

Ampliamos a base de 27 para 316 notícias do Status Invest. O recorte passou a incluir as editorias FIIs, Negócios e Fiagro, além das ações consideradas no início do projeto. Essa mudança permitiu treinar uma classificação de categorias editoriais sem criar rótulos a partir dos tickers.

A coleta ampliada foi feita em 19/10/2026. A categoria foi copiada do cabeçalho da própria notícia e fica acompanhada de sua URL. A coleta não representa todas as publicações do site: selecionamos notícias pela ordem das listagens de três editorias. As categorias podem se sobrepor em conteúdo e não passaram por nova anotação humana.

Categoria do site	Notícias
Negócios	116
FIIs	100
Fiagro	100

Analisamos título e corpo. Após a conferência, ficaram 316 documentos, publicados entre 2026-04-20 e 2026-10-19. Foram retirados 5 parágrafos promocionais, mantendo o texto bruto no CSV.

1 Atividades realizadas

Atividade	BoW	TF-IDF	Word2Vec	BERT
Agrupamento com PCA	X	X	X	X
Busca top 3 e top 5	X	X	X	X
Classificação editorial	X	X	X	X

Também executamos análise de sentimento dos títulos, reconhecimento de entidades e extração de relações candidatas. BERTimbau foi usado como representação fixa; a decisão da classificação foi feita por Regressão Logística, sem ajuste fino do BERT.

2 Avaliação dos agrupamentos

BoW e TF-IDF usam o mesmo vocabulário. Word2Vec foi treinado com Skip-gram, 100 dimensões, janela 5 e 60 épocas. BERTimbau usa a média dos vetores dos tokens; textos longos são divididos em blocos de 254 subtokens para aproveitar o corpo inteiro. Todos os vetores são normalizados.

K-Means foi executado com K de 2 a 8, sementes 7, 21 e 42 e 20 inicializações. O K candidato maximiza a média da silhueta de cosseno, evitando grupos unitários quando há outra opção. PCA foi aplicado depois, somente para visualizar os resultados.

Representação	K	Silhueta	DB	CH	ARI cat.	NMI	ARI sem.
BoW	4	0,1266	3,2700	13,8896	0,3414	0,4373	0,8847
TF-IDF	4	0,0653	4,6932	7,4789	0,3351	0,4285	0,8083
Word2Vec	4	0,3615	1,7031	53,9128	0,3400	0,4679	0,9960
BERT	2	0,2949	2,1202	64,5981	0,2113	0,2386	0,9915

Silhueta e Calinski-Harabasz são melhores quando maiores; Davies-Bouldin, quando menor. ARI cat. e NMI comparam os grupos com a editoria publicada pelo site. ARI sem. compara as três sementes e indica estabilidade. As categorias não foram usadas no ajuste dos grupos.

Entre os K candidatos, BoW teve a maior correspondência com as editorias pelo ARI (0,3414). Isso não significa que seja a melhor representação para toda tarefa: as métricas mudam com o espaço vetorial e com a escolha de K.

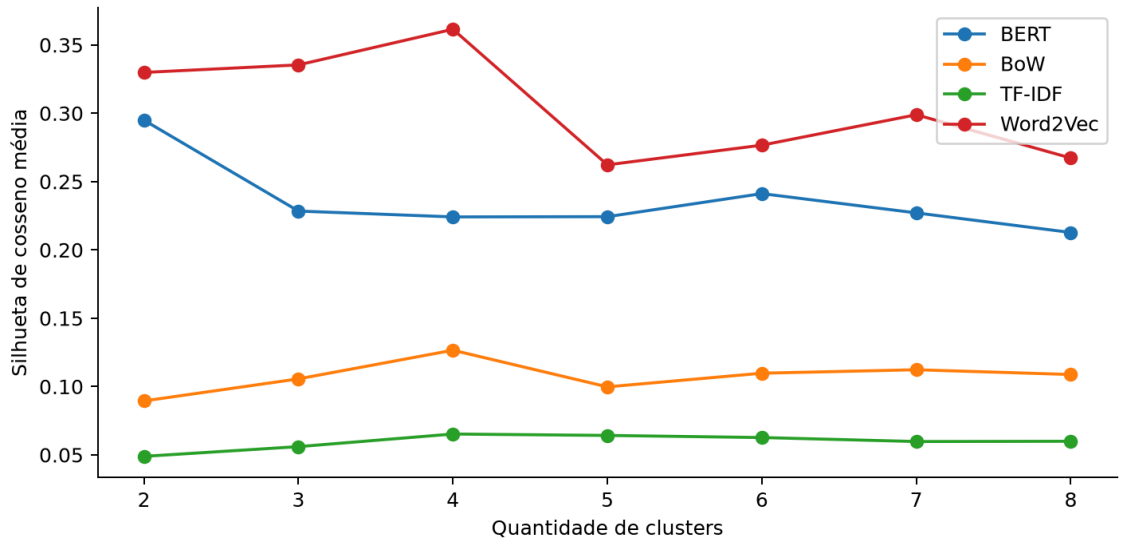


Figura 1 Silhueta média por quantidade de grupos. A tabela completa mantém as três execuções por configuração.

2 Coesão e leitura dos grupos

Representação	Intra média quadrática	Distância entre centros
BoW	0,7248	0,6694
TF-IDF	0,8500	0,5506
Word2Vec	0,1324	0,5230
BERT	0,0604	0,2278

A primeira medida é a inércia dividida pelo número de notícias. A segunda é a média das distâncias euclidianas entre centros. Elas foram calculadas nos vetores completos; são medidas diferentes, não valores para subtrair entre si. A normalização ajuda na comparação, mas não torna as geometrias dos quatro modelos idênticas.

Para examinar o conteúdo, mostramos abaixo os grupos do TF-IDF. As palavras de maior peso ajudam a dar um sentido ao grupo e os títulos centrais permitem conferir essa leitura. Um grupo pode misturar editorias quando há vocabulário financeiro em comum.

Grupo	N	Editorias	Palavras	Notícia central
0	72	Fiagro: 71; Negócios: 1	soja, snfz11, agronegócio, produção, mato	N239 SNFZ11 surfa avanço do agro brasileiro que já superou meta global para 2050
1	13	FIIs: 13	pontos, dia, máxima, índice, sessão	N095 IFIX cai 0,37% e fecha pregão em 3.732,49 pontos
2	96	Negócios: 75; FIIs: 18; Fiagro: 3	companhia, ações, não, mercado, sobre	N131 Petrobras (PETR4) melhora caixa e mantém tese de dividendos
3	135	FIIs: 69; Negócios: 40; Fiagro: 26	cota, fundo, distribuição, agosto, carteira	N002 Dividendos do MCRE11 superam 1,3% em outubro; veja quem recebe

A maior correspondência com editorias pelo ARI foi indicada na tabela anterior. A escolha por silhueta pode favorecer uma divisão mais ampla do que as três categorias publicadas. Por isso, avaliamos separadamente a compactação dos vetores e a interpretação dos assuntos.

2 Projeções dos agrupamentos

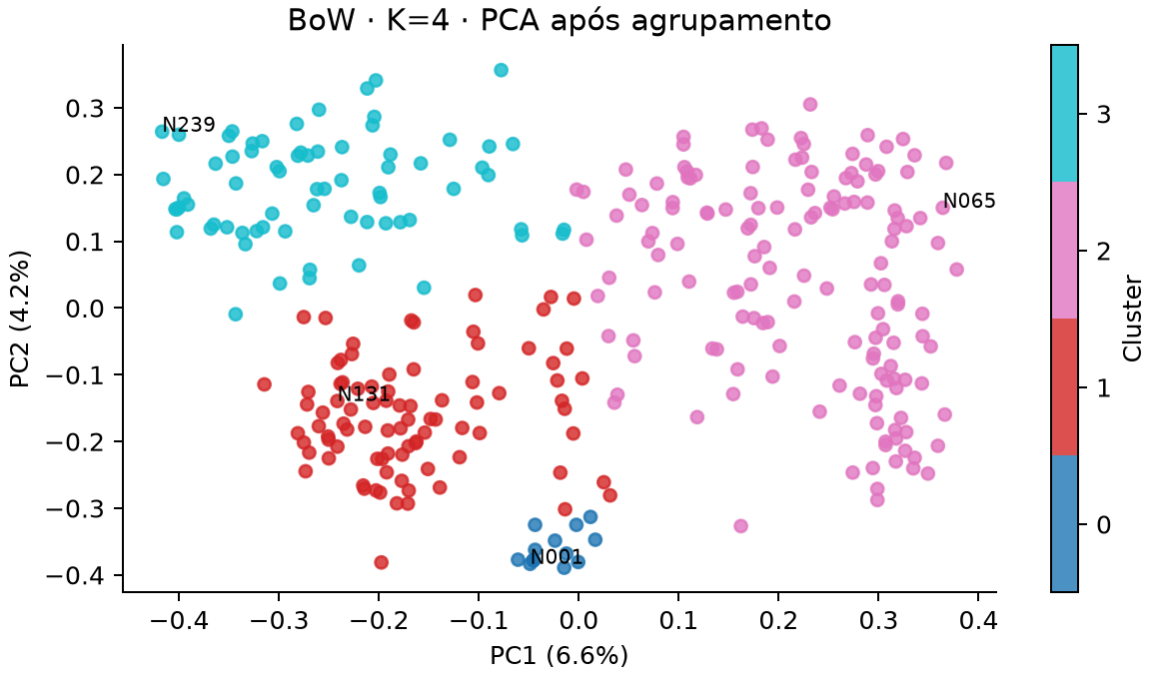


Figura 2 BoW: K=4; os dois eixos preservam 10.8% da variância. Os códigos destacam documentos próximos dos centros.

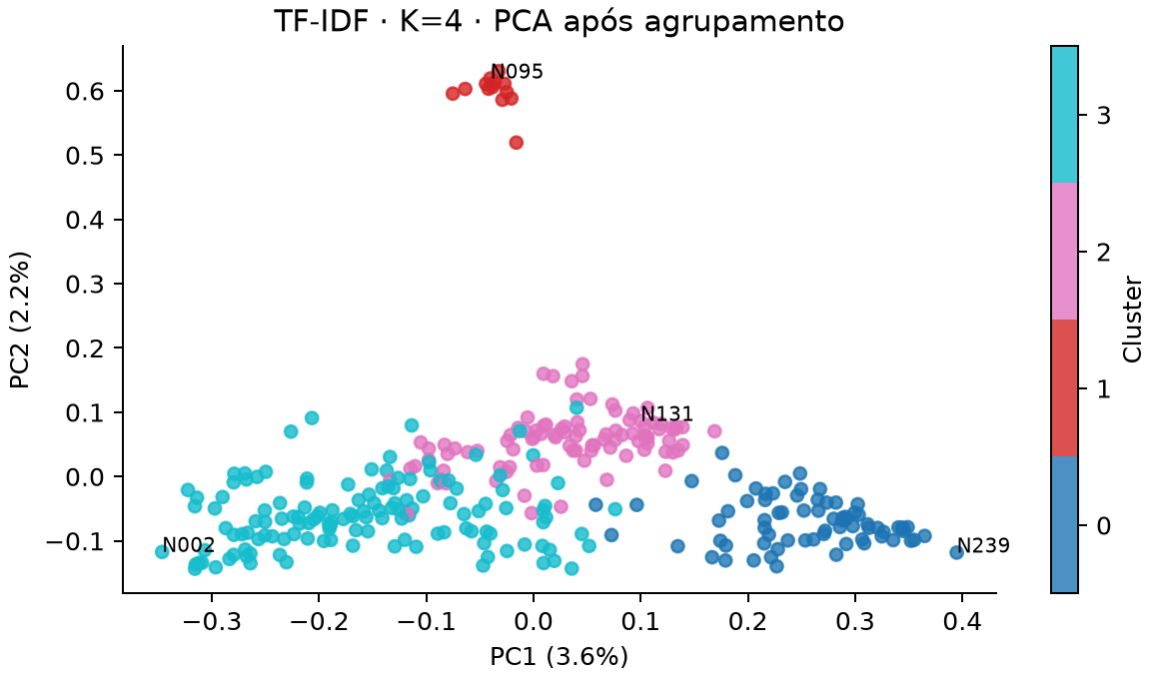


Figura 3 TF-IDF: K=4; os dois eixos preservam 5.8% da variância. Os códigos destacam documentos próximos dos centros.

O PCA comprime o espaço original em dois eixos. Sobreposição ou separação na figura não substitui a avaliação dos vetores completos nem a leitura das notícias.

2 Projeções dos agrupamentos

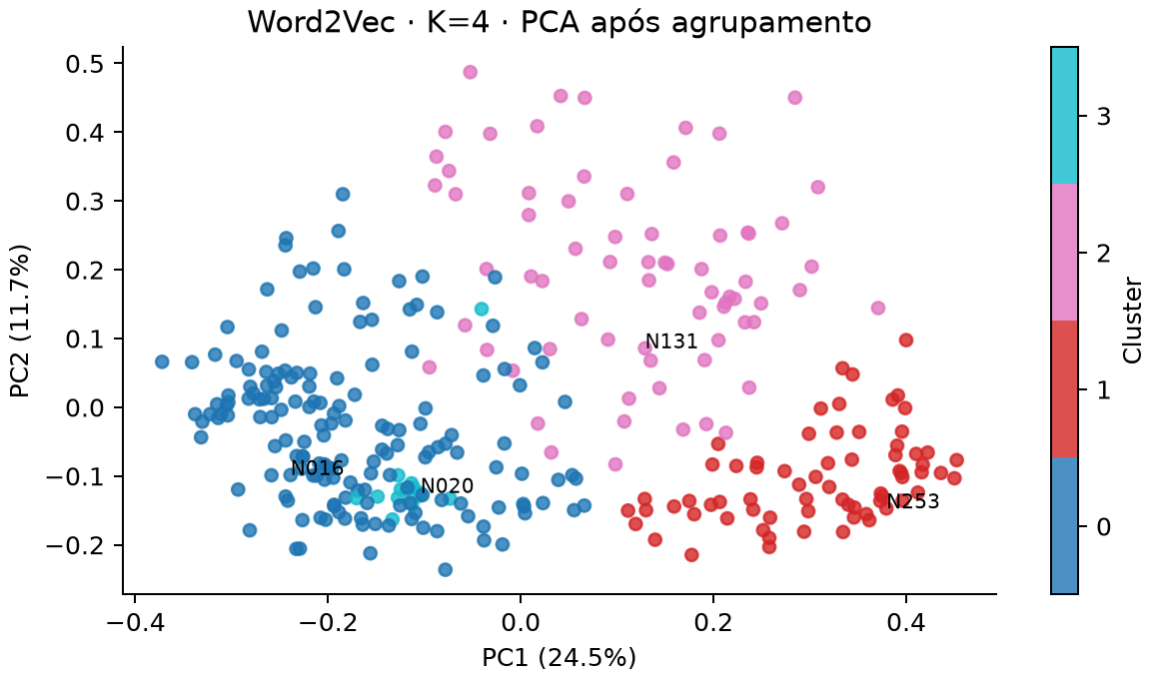


Figura 4 Word2Vec: K=4; os dois eixos preservam 36.3% da variância. Os códigos destacam documentos próximos dos centros.

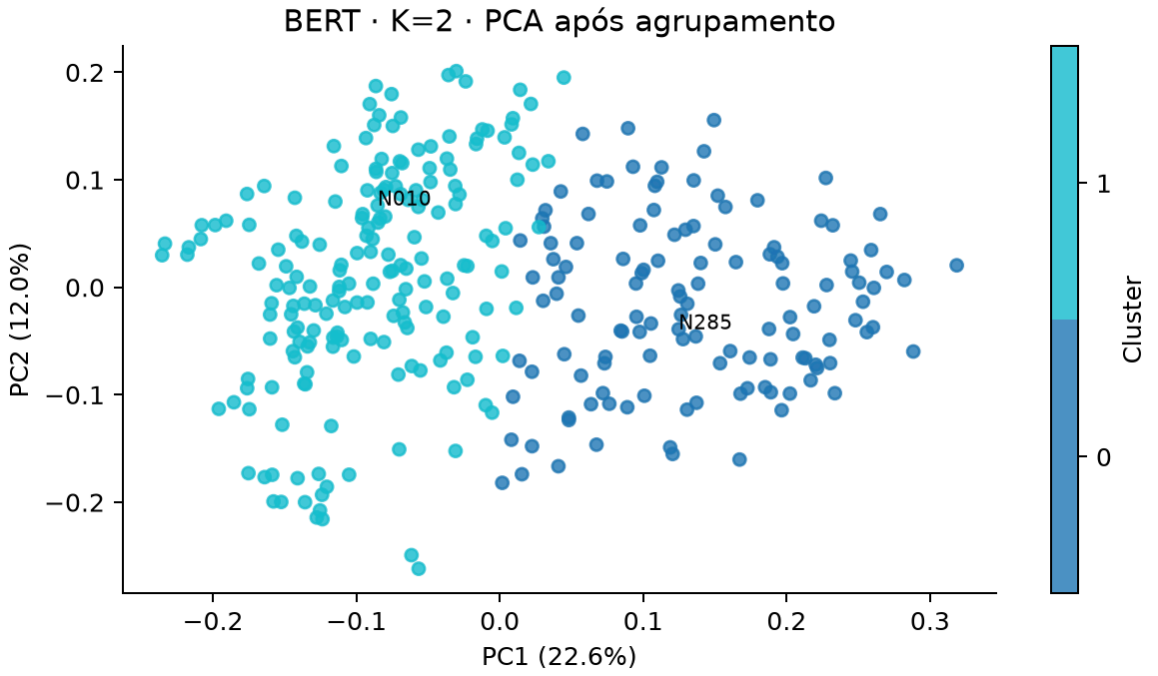


Figura 5 BERT: K=2; os dois eixos preservam 34.6% da variância. Os códigos destacam documentos próximos dos centros.

O PCA comprime o espaço original em dois eixos. Sobreposição ou separação na figura não substitui a avaliação dos vetores completos nem a leitura das notícias.

3 Busca e recomendação

Comparamos sete consultas iguais nas quatro representações, com similaridade de cosseno. A transformação da consulta usa o modelo já ajustado. O top 3 corresponde às três primeiras linhas do top 5. As pontuações não são probabilidades e não devem ser comparadas diretamente entre modelos.

Exemplo de consulta: Petrobras dividendos

BoW

Pos.	Código	Título recuperado	Cosseno
1	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do petróleo?	0,3240
2	N132	Petrobras (PETR4) vai pagar R$ 17,4 bilhões em proventos	0,2457
3	N131	Petrobras (PETR4) melhora caixa e mantém tese de dividendos	0,2269
4	N304	Petrobras (PETR4) fecha R$ 60 bilhões em contratos; entenda	0,2021
5	N303	Petrobras supera Prio (PRIO3) em trade de valor relativo da EQI	0,1943

TF-IDF

Pos.	Código	Título recuperado	Cosseno
1	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do petróleo?	0,2098
2	N304	Petrobras (PETR4) fecha R$ 60 bilhões em contratos; entenda	0,1746
3	N132	Petrobras (PETR4) vai pagar R$ 17,4 bilhões em proventos	0,1696
4	N303	Petrobras supera Prio (PRIO3) em trade de valor relativo da EQI	0,1647
5	N313	Petrobras (PETR4) fecha acordo para adquirir parte de campo; veja detalhes	0,1609

Word2Vec

Pos.	Código	Título recuperado	Cosseno
1	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do petróleo?	0,6856
2	N134	Itaúsa (ITSA4) ou Itaú (ITUB4): holding ou banco, quem paga mais dividendos?	0,6012
3	N132	Petrobras (PETR4) vai pagar R$ 17,4 bilhões em proventos	0,5948
4	N178	Dividendo na área: veja os FIIs que pagam proventos aos cotistas hoje	0,5919
5	N303	Petrobras supera Prio (PRIO3) em trade de valor relativo da EQI	0,5907

BERT

Pos.	Código	Título recuperado	Cosseno
1	N164	ALZC11 e mais FIIs pagam dividendos nesta terça-feira (23)	0,4105
2	N178	Dividendo na área: veja os FIIs que pagam proventos aos cotistas hoje	0,4092
3	N134	Itaúsa (ITSA4) ou Itaú (ITUB4): holding ou banco, quem paga mais dividendos?	0,4089
4	N025	Dividendos de FIIS serão pagos aos cotistas hoje; confira	0,4070

Pos.	Código	Título recuperado	Cosseno
5	N122	Ambev entra no top 10 de ações mais negociadas em julho	0,4047

3 Comparação das consultas

Q1: Petrobras dividendos ; Q2: Vale produção minério de ferro ; Q3: Itaú lucro resultado ; Q4: WEG receita lucro ; Q5: Banco do Brasil dividendos ; Q6: dividendos fundos imobiliários ; Q7: agronegócio CRA rendimentos

Busca	Modelo	Código	Primeira notícia recuperada
Q1	BoW	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do...
Q1	TF-IDF	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do...
Q1	Word2Vec	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do...
Q1	BERT	N164	ALZC11 e mais FIIs pagam dividendos nesta terça-feira (23)
Q2	BoW	N308	Vale (VALE3) eleva projeções e prevê ganho extra bilionário em 2026
Q2	TF-IDF	N308	Vale (VALE3) eleva projeções e prevê ganho extra bilionário em 2026
Q2	Word2Vec	N308	Vale (VALE3) eleva projeções e prevê ganho extra bilionário em 2026
Q2	BERT	N304	Petrobras (PETR4) fecha R$ 60 bilhões em contratos; entenda
Q3	BoW	N310	Itaú (ITUB4) tem lucro 10,4% maior, mas crédito esfria no 1T26
Q3	TF-IDF	N310	Itaú (ITUB4) tem lucro 10,4% maior, mas crédito esfria no 1T26
Q3	Word2Vec	N128	Fleury (FLRY3) eleva lucro e aprova R$ 217,8 mi em JCP
Q3	BERT	N134	Itaúsa (ITSA4) ou Itaú (ITUB4): holding ou banco, quem paga mais...
Q4	BoW	N137	WEG (WEGE3): tarifaço pesa no radar, mas IA ainda sustenta tese
Q4	TF-IDF	N137	WEG (WEGE3): tarifaço pesa no radar, mas IA ainda sustenta tese
Q4	Word2Vec	N137	WEG (WEGE3): tarifaço pesa no radar, mas IA ainda sustenta tese
Q4	BERT	N136	Petrobras (PETR4) ou PRIO (PRIO3): quem vence esse duelo do...
Q5	BoW	N134	Itaúsa (ITSA4) ou Itaú (ITUB4): holding ou banco, quem paga mais...
Q5	TF-IDF	N134	Itaúsa (ITSA4) ou Itaú (ITUB4): holding ou banco, quem paga mais...
Q5	Word2Vec	N134	Itaúsa (ITSA4) ou Itaú (ITUB4): holding ou banco, quem paga mais...
Q5	BERT	N178	Dividendo na área: veja os FIIs que pagam proventos aos cotistas...
Q6	BoW	N033	Dividendos de 180 FIIs são anunciados com yield de até 3,31%
Q6	TF-IDF	N043	Dividendos hoje: três FIIs fazem pagamentos nesta sexta-feira (9)
Q6	Word2Vec	N164	ALZC11 e mais FIIs pagam dividendos nesta terça-feira (23)
Q6	BERT	N178	Dividendo na área: veja os FIIs que pagam proventos aos cotistas...
Q7	BoW	N224	Brasil e Índia ampliam aproximação e podem abrir novas...
Q7	TF-IDF	N206	XPCA11 registra perda milionária, mas mantém dividendos com...
Q7	Word2Vec	N258	IAAG11 confirma R$ 0,12 por cota e eleva carrego a CDI +3,1%
Q7	BERT	N256	SNFZ11 ganha tração com safrinha de milho forte em MT

Na consulta Petrobras dividendos, BoW, TF-IDF e Word2Vec colocaram em primeiro um comparativo entre Petrobras e PRIO. Há relação com a empresa, mas o título não responde diretamente à busca por dividendos. O BERT colocou uma notícia de pagamentos de FIIs, relacionada a dividendos e sem a empresa pedida. Esse caso mostra por que o assunto e a entidade precisam ser conferidos juntos.

Para uso no projeto, os resultados servem como candidatos a notícias relacionadas. Um filtro por empresa, combinação de TF-IDF com embeddings e revisão dos primeiros resultados podem melhorar a navegação. A comparação completa dos top 3 e top 5 está em buscas_top5.csv.

4 Avaliação da classificação

A tarefa multiclasse prevê a categoria primária editorial do site. Títulos com o mesmo molde ou similaridade de caracteres de pelo menos 0,92 foram agrupados antes da divisão. Nenhum grupo ou URL aparece ao mesmo tempo no treino e no teste. Isso reduz a repetição de manchetes quase iguais entre os conjuntos, mas não elimina todas as semelhanças entre notícias.

Categoria	Treino	Teste
FIIs	80	20
Fiagro	80	20
Negócios	93	23

Treino: 253 notícias. Teste reservado: 63. Dentro do treino, a validação em três partes agrupadas escolheu TF-IDF pelo F1 macro médio. Não usamos o teste para ajustar parâmetros ou escolher a representação.

O modelo de decisão é Regressão Logística, com C=1 e pesos de classe balanceados. BoW, TF-IDF e Word2Vec são ajustados apenas no respectivo treino, inclusive em cada parte da validação. Os embeddings BERT são fixos e não usam os rótulos da base.

Representação	F1 validação	Acurácia teste	F1 macro teste
BoW	0,9067	0,9524	0,9521
TF-IDF	0,9294	0,9683	0,9690
Word2Vec	0,8189	0,8254	0,8280
BERT	0,7361	0,7778	0,7772

A referência que sempre prevê a classe mais frequente teve acurácia 0,3651 e F1 macro 0,1783 no mesmo teste. O F1 macro dá o mesmo peso a cada categoria.

FIIs versus demais editorias

Representação	Acurácia	F1 macro	F1 FIIs
BoW	0,9524	0,9458	0,9268
TF-IDF	0,9841	0,9814	0,9744
Word2Vec	0,8413	0,8317	0,7917
BERT	0,8413	0,8317	0,7917

O TF-IDF teve o maior F1 macro na validação e no teste desta divisão. Word2Vec e BERT ficaram abaixo das representações lexicais. Isso sugere que o vocabulário das editorias foi útil neste recorte; não demonstra uma superioridade geral do TF-IDF sobre embeddings.

A tarefa binária usa a mesma divisão e as mesmas representações. Ela é mais específica: identifica notícias publicadas na editoria FIIs, sem tentar separar Negócios de Fiagro.

4 Erros e comportamento com textos novos

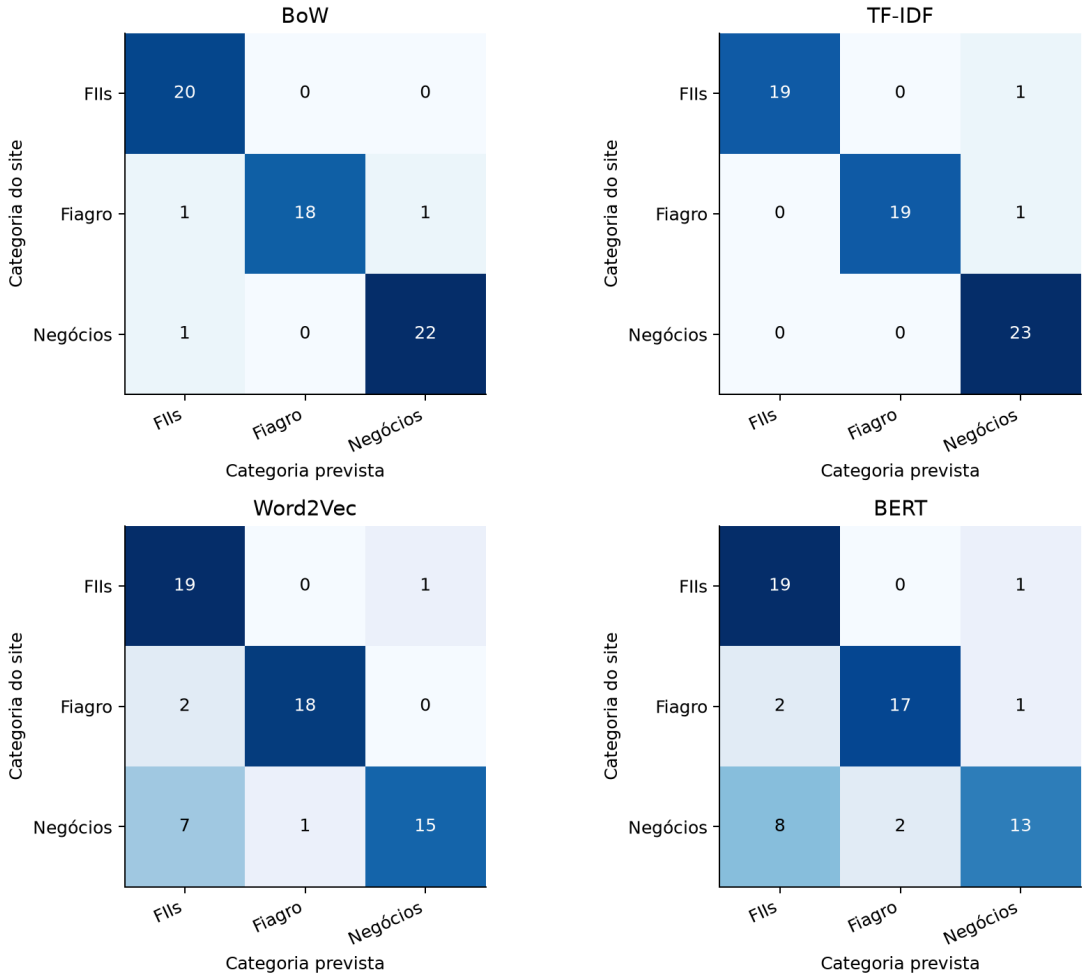


Figura 6 Matrizes de confusão no teste. Linhas indicam a categoria publicada pelo site; colunas indicam a previsão.

O modelo escolhido na validação errou 2 de 63 notícias do teste. As matrizes mostram quais editorias se confundem. A distinção pode ser difícil porque as três categorias tratam de investimentos, resultados e rendimentos.

Código	Categoria do site	Previsão	Título
N028	FIIs	Negócios	RBVA11 recebe nota acima da média da Moody’s
N298	Fiagro	Negócios	Copom deve cortar Selic; SNAG11 mantém atratividade com spread

4 Demonstração com textos novos

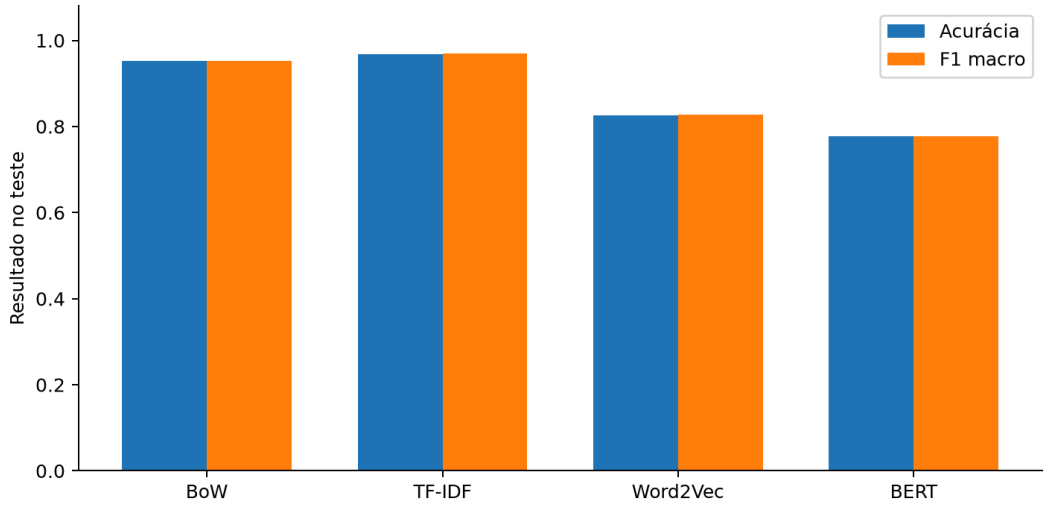


Figura 7 Acurácia e F1 macro das quatro representações no mesmo teste reservado.

Frase	Esperada no exemplo	Prevista	Prob.
A empresa ampliou o lucro e anunciou a distribuição de dividendos aos...	Negócios	Negócios	0,6251
A fabricante divulgou crescimento da receita e vai investir em uma...	Negócios	Negócios	0,5284
O fundo imobiliário comprou um galpão logístico e reduziu a vacância...	FIIs	Negócios	0,4947
O fundo de shopping centers anunciou rendimentos mensais aos cotistas.	FIIs	Negócios	0,4276
O fundo do agronegócio comprou certificados de recebíveis ligados à...	Fiagro	Fiagro	0,5128
O Fiagro anunciou a compra de uma fazenda e novos investimentos em CRAs.	Fiagro	Fiagro	0,4799

As duas frases curtas sobre fundos imobiliários foram previstas como Negócios. Isso contrasta com a acurácia alta nas notícias completas do teste e mostra uma limitação de uso: frases genéricas e sem o contexto dos artigos podem ter outro comportamento.

Essas seis frases foram escritas para demonstrar o uso e não entram nas métricas. As probabilidades não foram calibradas; um valor alto não garante que a previsão esteja correta. Um teste com notícias de outra data e de outro veículo ainda seria necessário para verificar generalização.

5 Sentimento dos títulos

Usamos FinBERT-PT-BR, já treinado externamente para textos financeiros em português. A entrada foi o título. O mapeamento da documentação é positivo, negativo e neutro, nessa ordem de índices 0, 1 e 2.

Previsão	Títulos
positivo	150
neutro	110
negativo	56

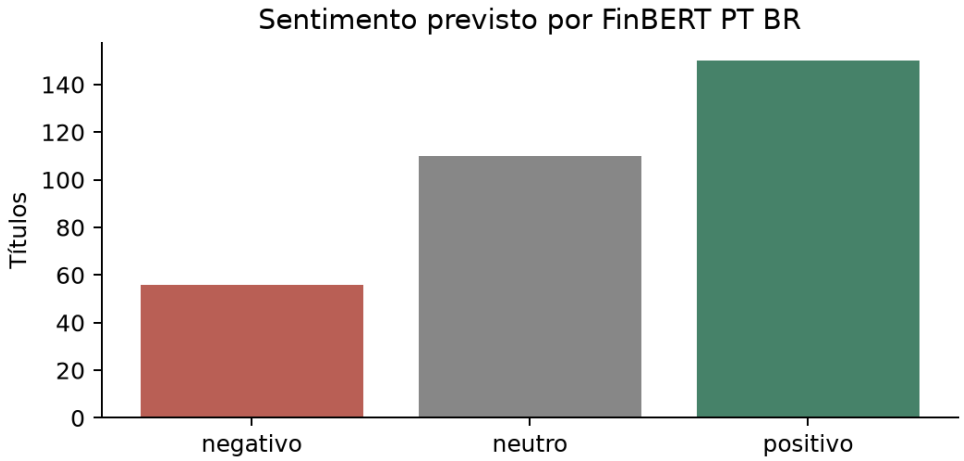


Figura 8 Distribuição das previsões de sentimento. Não há gabarito de polaridade revisado nesta base.

Código	Previsão	Título
N001	positivo	IFIX avança 0,43% e alcança 3.956,84 pontos
N002	negativo	Dividendos do MCRE11 superam 1,3% em outubro; veja quem recebe
N003	neutro	Por dentro do HGLG11: veja os galpões, contratos e dividendos do fundo

Uma previsão discutível é N002: o título destaca dividendos acima de 1,3%, mas o modelo previu sentimento negativo. O exemplo mostra por que a saída não deve ser tomada como uma leitura confirmada da notícia.

Esses resultados podem ajudar a filtrar manchetes para leitura, mas não medem o retorno de uma ação nem o desempenho do modelo. Uma notícia pode mencionar lucro e queda de preço na mesma frase. A categoria editorial também não é um rótulo de sentimento e não pode validar a polaridade prevista.

5 Entidades e relações

O spaCy pt_core_news_sm encontrou 8482 menções e 2078 pares distintos de expressão e tipo. A saída inclui texto da entidade, PER, ORG, LOC ou MISC, posições e código do documento.

Expressão prevista	Tipo	Menções	Documentos
R$	MISC	2076	274
Imposto de Renda	MISC	83	80
yield	MISC	98	72
FIIs	ORG	149	65
Brasil	LOC	88	56
CDI	ORG	110	53
FII	ORG	73	53
CRIs	MISC	106	45

CDI aparece como ORG, embora seja um índice de referência, e FIIs aparece como se fosse uma organização específica. Esses exemplos mostram limitações do modelo geral ao lidar com termos financeiros.

A frequência ajuda a criar filtros por empresa, pessoa ou local, mas não representa importância financeira. O modelo pequeno pode confundir nomes de empresas com locais e símbolos monetários com entidades. Os exemplos e os tipos precisam de revisão antes de alimentar um índice público.

Relações candidatas

A regra de dependências encontrou 1648 candidatos. Ela procura uma entidade nomeada como sujeito de um verbo e um complemento na mesma frase, conservando evidência e negação.

Código	Sujeito	Verbo	Complemento
N001	IFIX	encerrar	o pregão desta segunda-feira (19)
N003	FII	reunir	Com presença em diferentes regiões do país,
N004	XPML11	anunciar	dividendos para outubro

N001: “O IFIX encerrou o pregão desta segunda-feira (19) aos 3.956,84 pontos, alta de 0,43%.”

N003: “Com presença em diferentes regiões do país, o FII reúne locatários ligados ao comércio eletrônico, à indústria e às operações logísticas.”

N004: “XPML11 anuncia dividendos para outubro;”

O total não corresponde a fatos confirmados. A regra pode perder sujeitos, juntar complementos extensos ou extrair uma relação incompleta. Ela não resolve pronomes, voz passiva e coordenação de forma completa. No projeto, os candidatos servem para destacar trechos e apoiar uma revisão, mantendo a notícia de origem.

6 Contribuição para o projeto

O projeto começou com coleta e preparação de notícias sobre ações brasileiras. A base ampliada permite explorar também fundos imobiliários e agronegócio. A busca encontra notícias relacionadas; os agrupamentos ajudam a navegar pelo acervo; a classificação sugere a editoria de uma notícia nova.

A classificação agora foi treinada e medida em documentos reservados, com uma referência simples e validação restrita ao treino. Isso acrescenta uma etapa verificável ao projeto. Ainda assim, a base vem de um único veículo e foi selecionada por conveniência. O resultado mede a capacidade de reproduzir as três editorias neste recorte, não qualquer taxonomia financeira.

Entidades podem virar filtros por organização ou pessoa. Sentimento pode destacar títulos para leitura, e as relações podem apontar passagens relevantes. Esses recursos precisam permitir correção e acesso ao texto original. Não testamos uma estratégia de investimento.

A divisão foi agrupada e estratificada, sem um corte temporal comum. As editorias também cobrem intervalos diferentes. Para continuar, seria necessário ampliar o período, conferir rótulos e erros com pessoas e avaliar notícias futuras. A coleta, os gráficos e as métricas desta entrega são resultados reais da execução registrada; as limitações da busca, do sentimento e da extração não foram tratadas como acertos confirmados.

Declaração do uso de IA generativa

Utilizamos OpenAI GPT-6, no Codex, na coleta, implementação e correção do notebook, interpretação dos resultados e redação. As métricas e os gráficos foram calculados em Python. BERTimbau, FinBERT e spaCy foram executados localmente. A interpretação qualitativa também teve ajuda de IA e não equivale a validação humana independente.

Os trechos reais das instruções usadas estão em prompts_utilizados.txt. O roteiro a seguir contém 19 exemplos hipotéticos organizados por etapa, sem representar um histórico de conversas.

Roteiro de prompts da coleta aos agrupamentos

Exemplos hipotéticos de pedidos de apoio, organizados na ordem das etapas realizadas.

1. “Leia o PDF da Unidade 3 e confira as aulas 6, 7, 8 e 9. Me ajude a organizar o que precisamos fazer nas questões 1 a 6 e o que podemos aproveitar do notebook anterior, sem alterar o GitHub.”
2. “Amplie a coleta no Status Invest para FIIs, Negócios e Fiagro. Copie a categoria do cabeçalho de cada notícia, registre a URL de origem e mantenha pausas entre os acessos.”
3. “Salve título, texto, data, autor, tickers e categoria publicada pelo site. Depois confira os campos vazios, as repetições, o período da base e a quantidade de notícias por categoria.”
4. “Me ajude a limpar propaganda e chamadas do site sem apagar o texto original. Prepare os tokens em português, preservando a palavra não e os tickers, e mantenha lemas e radicais em colunas separadas.”
5. “Quero comparar BoW e TF-IDF nas notícias que coletamos. Me ajude a implementar os dois usando os mesmos textos e o mesmo vocabulário para a comparação fazer sentido.”
6. “Preciso acrescentar Word2Vec ao notebook. Use Skip-gram e mostre como transformar cada notícia na média dos vetores das palavras. Confira também quantas palavras ficaram fora do vocabulário.”
7. “Gostaria de comparar esses resultados com BERTimbau. Me ajude a incluir o modelo sem ajuste fino e a dividir as notícias longas em blocos, aproveitando todo o texto para formar o vetor final.”
8. “Confira se as quatro representações usam as mesmas notícias na mesma ordem. Normalize os vetores e teste o K-Means com 2 a 8 grupos e três sementes diferentes, guardando os resultados.”
9. “Calcule silhueta, Davies-Bouldin e Calinski-Harabasz para comparar os agrupamentos. Veja também as distâncias dentro e entre os grupos, a estabilidade entre sementes e se há grupos com uma única notícia.”
10. “Monte os gráficos de PCA com os grupos identificados por cores e mostre a variância explicada nos dois eixos. Use o PCA só para visualizar os grupos que já foram calculados.”

Roteiro de prompts das análises ao relatório

11. “Mostre as palavras mais frequentes e algumas notícias próximas do centro de cada grupo. Me ajude a comparar esses exemplos com as métricas e a explicar os grupos que ficaram misturados.”
12. “Quero criar uma busca por notícias usando similaridade de cosseno nos quatro modelos. A função deve receber uma consulta e mostrar os três ou cinco primeiros resultados, com título, URL e pontuação.”
13. “Teste as mesmas consultas nos quatro modelos, incluindo as cinco empresas do projeto e buscas sobre FIIs e agronegócio. Compare os resultados e confira os casos de empresa ou assunto errado.”
14. “Agora que temos categorias do site, separe treino e teste sem deixar títulos quase iguais nos dois conjuntos. Compare as quatro representações com Regressão Logística e escolha o modelo pela validação feita só no treino.”
15. “Me ajude a aplicar o FinBERT-PT-BR aos títulos das notícias. Confira as classes na documentação, faça um gráfico das previsões e separe exemplos positivos, negativos e neutros para comentar, sem apresentar as previsões como um gabarito.”

Como executar

Extraia o pacote e abra o notebook ampliado na pasta Unidade3_PLN_Ampliado. Mantenha dados/ junto do arquivo, instale requirements.txt e o modelo spaCy indicado na primeira seção e execute as células em ordem. A primeira execução baixa os modelos públicos e precisa de internet. Não é necessária chave da OpenAI.

Os parâmetros, versões, revisões dos modelos e hash da base estão em resultados/registro_execucao.json. As divisões de treino e teste e as previsões de cada documento também estão exportadas. O coletor é opcional: repetir a coleta pode alterar a amostra e os resultados.