

UNIVERSIDADE REGIONAL DE BLUMENAU
CENTRO DE CIÊNCIAS EXATAS E NATURAIS
CURSO DE CIÊNCIA DA COMPUTAÇÃO
Processamento de Linguagem Natural
Etapa Prática 1 - Coleta de Dados e Pré-processamento de Dados

Equipe: Marcos Borgert e Vitor Gustavo Hornburg

Link repositório: https://github.com/vitorHornburg/PLN_Furb/

Dimensão	Crterios de avaliao	Peso	Observaes
Base de dados textuais	Justificativa e explicao da escolha Adequao dos dados às tarefas de PLN (volume, abrangncia, variedade) Organizao e interpretabilidade da base de dados (dicionrio de dados)	0,4	Justificativa e explicao da escolha A base textual foi construda a partir de notcias do mercado financeiro publicadas no Status Invest. Escolhemos notcias do mercado financeiro porque elas trazem contedos sobre empresas e aes da B3, como resultados, dividendos, negociaes e outros acontecimentos das empresas. As notcias so interessantes para PLN porque possuem texto em linguagem natural e podem ser utilizadas futuramente em tarefas como classificao por assunto, anlise de sentimento, busca de notcias relacionadas a uma empresa e extrao de informaes. Adequao dos dados às tarefas de PLN A coleta percorre pginas de notcias e identifica os tickers encontrados no ttulo e no contedo. Dessa forma, uma mesma notcia pode estar relacionada a diferentes empresas. A quantidade de pginas percorridas pode ser aumentada para ampliar o volume da base. Os textos tambm apresentam variedade de tamanho, assunto e empresas citadas. Isso permite trabalhar com contedos diferentes dentro do mesmo domnio financeiro e aplicar as etapas de limpeza e preparao vistas na disciplina. Organizao e interpretabilidade Os dados so armazenados em arquivos CSV. A base bruta contm URL, ttulo, data de publicao, autor, texto original e tickers encontrados. O texto original é mantido para que seja possvel consultar o contedo exatamente como foi coletado. Também é gerada uma base processada com novas colunas para texto limpo, tokens, tokens normalizados, tokens sem stopwords, lemas e stems. Assim, é possvel comparar o texto original com cada etapa do pré-processamento sem perder os dados coletados.
Script Python (scraping, acesso via API, outros mtodos)	Funcionamento e reprodutibilidade Documentao dos procedimentos realizados (comentrios ou texto markdown no notebook) Criatividade / capacidade de resoluo de problemas	0,3	Coleta dos dados A coleta foi desenvolvida em Python utilizando requests e BeautifulSoup. Primeiro, o script percorre as pginas de notcias do Status Invest e reúne os links encontrados. Depois, acessa cada notcia individualmente para obter URL, ttulo, data de publicao, autor e texto. Quando a pgina possui dados estruturados em JSON-LD, o script tenta utilizar essas informaes. Caso algum campo no seja encontrado dessa forma, so utilizados elementos do HTML como alternativa. Essa abordagem foi adotada para deixar a coleta menos dependente de um nico elemento da pgina. Funcionamento e reprodutibilidade A quantidade de pginas e o intervalo entre as requisies ficam definidos no incio do notebook, facilitando uma nova

			execução. Os links são armazenados sem repetição e erros durante a leitura de uma notícia são tratados para que a coleta possa continuar. Depois da coleta, os tickers são identificados no título e no texto por meio de uma expressão regular. O notebook mostra a quantidade de notícias coletadas, valores ausentes, URLs e títulos duplicados e a distribuição dos tickers encontrados. Documentação O notebook foi dividido em etapas e possui textos em Markdown explicando a coleta, o dicionário de dados, a limpeza e cada procedimento de pré-processamento. Ao final são exportados os arquivos CSV com a base bruta e a base processada.
Limpeza e preparação dos dados	Dados foram tokenizados? Dados foram normalizados? Remoção de ruídos Remoção de stopwords e pontuação	0,3	1. Limpeza dos textos O texto original é mantido na coluna texto_bruto. A limpeza é feita em uma nova coluna chamada texto_limpo. Nessa etapa são removidas URLs presentes no conteúdo, possíveis tags HTML, marcações como H2, quebras de linha e espaços repetidos. Assim, o conteúdo original continua disponível para comparação. 2. Tokenização Depois da limpeza, cada notícia é dividida em tokens com o word_tokenize do NLTK configurado para português. A tokenização transforma um texto contínuo em unidades menores, como palavras, números e sinais de pontuação, permitindo trabalhar com cada elemento separadamente nas próximas etapas. Por exemplo, uma frase como "Petrobras anunciou novos investimentos." pode ser separada em ["Petrobras", "anunciou", "novos", "investimentos", "."]. 3. Normalização Os tokens são convertidos para letras minúsculas utilizando casefold(). Também são mantidos somente tokens formados por caracteres alfabéticos. Com isso, sinais de pontuação e números deixam de fazer parte da representação normalizada, enquanto os acentos das palavras são preservados. 4. Remoção de stopwords Após a normalização são removidas stopwords da língua portuguesa utilizando a lista do NLTK. São palavras muito frequentes, como artigos e preposições, que podem ter pouca utilidade para diferenciar os textos. A palavra "não" foi preservada. Essa decisão foi tomada porque uma negação pode alterar o sentido de uma frase e pode ser importante caso a base seja utilizada posteriormente em uma análise de sentimento. Ao final dessas etapas, cada notícia mantém tanto o texto original quanto as diferentes representações criadas durante o pré-processamento.
Bonus round	Stemming e lematização Bases adicionais (ex.: comparação entre diferentes fontes ou recortes amostrais) Automatização na coleta (ex.: atualização periódica do scraping.)	Até 0,3	Stemming e lematização Além das etapas principais, foram criadas duas representações adicionais dos textos. Na lematização foi utilizado o modelo pt_core_news_sm do spaCy. A técnica procura transformar palavras flexionadas em uma forma canônica. Por exemplo, formas no plural ou verbos flexionados podem ser aproximados de uma forma base, deixando o resultado mais fácil de interpretar. Para o stemming foi utilizado o RSLPStemmer do NLTK, desenvolvido para português. Nesse caso, as palavras são reduzidas a radicais por regras de corte. O resultado pode não ser uma palavra completa, mas permite aproximar diferentes variações de um mesmo termo.

		As duas versões são mantidas separadamente no arquivo processado para permitir comparação posterior. Atualização da coleta O notebook também possui uma função para juntar uma nova coleta a um arquivo histórico. Antes de salvar, URLs repetidas são removidas. Assim, o mesmo processo pode ser executado novamente para incorporar notícias novas sem manter registros duplicados.
--	--	--